

THÔNG BÁO

V/v yêu cầu sản phẩm tham gia cuộc thi HSU AI-Driven Challenge 2026

I. TỔNG QUAN BÀI TOÁN

- Trong kỷ nguyên bùng nổ của các Mô hình Ngôn ngữ Lớn (LLMs), việc đảm bảo an toàn hệ thống trước các cuộc tấn công phi kỹ thuật thông qua dữ liệu đầu vào (Prompt) là một thách thức lớn. Các kỹ thuật như Prompt Injection và Jailbreaking cố tình thao túng mô hình để bỏ qua các rào cản an toàn, nhằm trích xuất thông tin độc hại, tạo nội dung thù ghét, hoặc phá hoại hệ thống cốt lõi.
- Cuộc thi AI-Driven Challenge yêu cầu các đội thi thiết kế và tối ưu một Hệ thống phòng vệ & Sàng lọc tự động (Prompt Firewall / Guardrail Model). Hệ thống này có nhiệm vụ phân tích, đánh giá, phát hiện và ngăn chặn thời gian thực các câu prompt chứa ý đồ xấu trước khi chúng được gửi tới mô hình AI xử lý chính.

II. NGUỒN DỮ LIỆU HUẤN LUYỆN

- Các đội thi được phép và khuyến khích sử dụng kết hợp 4 nguồn dữ liệu mở tiêu chuẩn quốc tế sau đây để xây dựng giải pháp:
 1. **BeaverTails**: Cung cấp các cặp Prompt-Response được gán nhãn chi tiết theo 14 danh mục an toàn (bạo lực, phân biệt đối xử, vi phạm pháp luật...).
 - Link : <https://github.com/PKU-Alignment/BeaverTails>
 2. **WildChat-1M**: Tập dữ liệu chứa 1 triệu lượt hội thoại thực tế giữa người dùng và chatbot. Đây là nguồn tài nguyên quý giá để mô hình học cách phân biệt hành vi trò chuyện thông thường và các mẫu prompt độc hại ẩn giấu trong bối cảnh thực hành.
 - Link : <https://huggingface.co/datasets/allenai/WildChat-1M>
 3. **Toxic-Chat**: Tập dữ liệu tập trung mạnh vào các hành vi tấn công mạng qua prompt (Prompt Injection, Toxic/ Hate speech).
 - Link : <https://huggingface.co/datasets/lmsys/toxic-chat>
 4. **Safety Moderation Benchmark**: Bộ dữ liệu chuẩn (Benchmark) chuyên biệt dùng để kiểm thử và đánh giá độ nhạy của các bộ lọc kiểm duyệt an toàn, giúp tối ưu tỷ lệ bỏ sót lỗi hoặc nhận diện nhầm bài toán.
 - Link : <https://huggingface.co/datasets/mvrcii/safety-moderation-benchmark>
- **Dữ liệu kiểm thử sử dụng cho việc đánh giá vòng sơ loại**: <https://byvn.net/x2Uz>

Lưu ý: Do các tập dữ liệu gốc chủ yếu sử dụng ngôn ngữ tiếng Anh, các đội thi cần chủ động thực hiện các phương pháp dịch thuật nếu muốn thực hiện trên tiếng Việt.

III. YÊU CẦU KỸ THUẬT ĐỐI VỚI SẢN PHẨM

Mỗi đội thi phải xây dựng một pipeline hoàn chỉnh đáp ứng 2 yêu cầu cốt lõi sau:

1. Khả năng phân loại

- Yêu cầu cơ bản: Hệ thống phải phân loại chính xác các câu Prompt đầu vào thành 2 nhóm: An toàn (Safe) hoặc Độc hại / Ý đồ xấu (Unsafe / Malicious).
- Yêu cầu nâng cao: Đối với các câu prompt thuộc nhóm Unsafe, hệ thống cần chỉ ra phân loại rủi ro (Ví dụ: Jailbreak, Hate Speech, Injection).

2. Tối ưu hiệu năng

- Hệ thống đóng vai trò là màng lọc đầu vào, do đó bắt buộc phải tối ưu hóa thời gian phản hồi (Latency/Inference Time).
- Đo lường thời gian xử lý trung bình trên một batch dữ liệu nhằm đảm bảo tính khả thi khi triển khai thực tế.

IV. PHƯƠNG THỨC CHẤM ĐIỂM VÀ ĐÁNH GIÁ

- Ban giám khảo sẽ tiến hành chấm điểm tự động bằng mã nguồn (Script) trên một tập dữ liệu thử nghiệm ẩn hoàn toàn (Private Test Set) để đảm bảo tính khách quan và thực chiến.
- Điểm số cuối cùng được tính toán dựa trên sự kết hợp giữa chất lượng giải thuật và tốc độ tác chiến:

$$\text{Tổng điểm} = (\text{Điểm Chất lượng} \times 60\%) + (\text{Điểm Tốc độ} \times 40\%)$$

Chi tiết:

- ❖ Điểm chất lượng phân loại (Trọng số 60%): Đánh giá bằng chỉ số *F1-Score*. Chỉ số này cân bằng giữa độ chính xác dự đoán mã độc và khả năng tránh chặn nhầm các prompt hợp lệ của người dùng.
 - ❖ Điểm tốc độ phản hồi (Trọng số 40%): Tính bằng thời gian thực thi (Inference Latency) để lọc sạch 10.000 câu prompt. Đội thi có thời gian xử lý ngắn nhất (tối ưu phần cứng tốt nhất) sẽ nhận điểm tối đa cho phần này, các đội tiếp theo sẽ bị trừ điểm theo tỷ lệ tuyến tính.
- Đối với vòng sơ loại và vòng bảng sẽ dựa vào Tổng điểm để phân thứ hạng.
 - Đối với vòng Chung kết sẽ kết hợp với Điểm đánh giá của Ban giám khảo, tỉ lệ kết hợp sẽ được công bố trong ngày diễn ra vòng Chung kết.

V. QUY ĐỊNH VỀ THƯ VIỆN VÀ CÔNG CỤ DÙNG CHUNG

- **Ngôn ngữ lập trình:** Python (≥ 3.8).
- **Thư viện xử lý NLP & Tiền xử lý:** Khuyến khích sử dụng underthesea, pyvi (cho tiếng Việt), nltk, spacy, scikit-learn.
- **Khung mô hình Deep Learning / LLM:** HuggingFace Transformers, PyTorch, hoặc TensorFlow. Được phép ứng dụng các mô hình mã nguồn mở như PhoBERT, BARTpho, hoặc kỹ thuật tinh chỉnh (LoRA/QLoRA) trên các dòng LLM nhỏ (như PhởGPT, Qwen, Llama) phù hợp chạy trên hạ tầng Colab/Kaggle..

Trên đây là Thông báo về việc yêu cầu sản phẩm tham gia cuộc thi HSU AI-Driven Challenge 2026 với chủ đề “Sàng lọc rủi ro, Làm chủ An ninh AI” diễn ra từ ngày 25/05/2026 đến ngày 15/08/2026. Yêu cầu các đội tham gia cuộc thi thực hiện đúng để sản phẩm tham dự đạt thành tích tốt nhất./.

Nơi nhận:

- Ban Giám hiệu (để b/c);
- Nhân sự Khoa (để t/h);
- Lưu: K.CNTT.

TRƯỞNG KHOA



Lê Đình Phong